

Zadanie 7. Własna metoda

Inteligentne Metody Optymalizacji

Maciej Szymaniak, 155830

Piotr Szymaczek, 155889

25 maja 2026

1 Opis zadania

Rozważamy zmodyfikowany problem komiwojażera. Dany jest zbiór n wierzchołków z symetryczną macierzą odległości d_{ij} oraz zyskiem p_i za odwiedzenie wierzchołka i . Należy wybrać podzbiór wierzchołków i ułożyć zamkniętą trasę przechodzącą przez wybrane wierzchołki, maksymalizującą funkcję celu:

$$f(\mathcal{C}) = \sum_{i \in \mathcal{C}} p_i - \sum_{(i,j) \in \mathcal{C}} d_{ij}.$$

Celem niniejszego zadania było zaproponowanie modyfikacji algorytmu z poprzednich laboratoriów lub nowej metody, która poprawia średni i najlepszy wynik na obu instancjach (TSPA, TSPB) w tym samym budżecie czasowym:

$$T_A = 1420 \text{ ms}, \quad T_B = 1578 \text{ ms}.$$

Bezpośrednim punktem odniesienia był algorytm **HAE2** (hybrydowy algorytm ewolucyjny z operatorem rekombinacji Op2 i lokalnym przeszukiwaniem SLS po rekombinacji), ale w Tabeli ?? porównujemy HAE-CLS ze wszystkimi najlepszymi metodami z poprzednich zadań – różne algorytmy dominują w różnych metrykach (ILS i LNS są mocniejsze niż HAE2 na TSPA, HAE2 jest mocniejszy na TSPB).

2 Opisana metoda: HAE-CLS

Zaproponowana metoda **HAE-CLS** (HAE z lokalnym przeszukiwaniem na sąsiedztwie kandydackim) to wariant HAE z Zadania 6 z trzema kluczowymi modyfikacjami wybranymi w wyniku eksperymentów (sekcja 4):

1. **Lokalne przeszukiwanie typu *candidate*** (CandLS) – zamiast pełnego SLS sąsiedztwo ograniczone do $k = 15$ najbliższych sąsiadów każdego wierzchołka. CandLS jest około 7–10× szybsze niż pełne SLS, więc w tym samym budżecie czasowym algorytm wykonuje 7–10× więcej iteracji ewolucyjnych.
2. **Operator rekombinacji Op1** (zamiast Op2 z HAE2). Op1 zachowuje izolowane wspólne wierzchołki obu rodziców jako 1-elementowe podtrasy; w kontekście CandLS daje to lepszy materiał startowy.
3. **Mniejsza populacja elitarna $P = 15$** (zamiast 20). Mniejsza populacja powoduje szybszą konwergencję i większą liczbę iteracji w budżecie czasowym.

Pozostałe elementy (sztuczna populacja *steady-state*, naprawa rozwiązań przez `repair_lns + phase2_remove` wbudowana w operatory rekombinacji, unikalność osobników po wartości funkcji celu, zastępowanie najgorszego osobnika populacji) pozostały bez zmian.

Kod źródłowy dostępny pod adresem:

<https://github.com/masz00/Intelligent-Optimization-Methods/tree/main/CustomMethod>

3 Pseudokody algorytmów

Algorithm 1: CandLS – lokalne przeszukiwanie z sąsiedztwem kandydackim (k najbliższych sąsiadów)

Wejście: Trasa x , macierz odległości D , lista zysków p , lista sąsiadów N ($N[v] = k$ najbliższych wierzchołków v)

Wyjście: Lokalnie optymalna trasa x

$improved \leftarrow \text{prawda};$

dopóki $improved$ **wykonaj**

$improved \leftarrow \text{fałsz}; \quad \Delta_{best} \leftarrow 0; \quad m_{best} \leftarrow \emptyset;$

$n \leftarrow |x|; \quad pos[v] \leftarrow -1$ dla wszystkich $v; \quad pos[x[i]] \leftarrow i$ dla $i = 0, \dots, n-1;$

dla każdego $i = 0, \dots, n-1$ **wykonaj**

$v \leftarrow x[i]; \quad w \leftarrow x[(i+1) \bmod n];$

dla każdego $u \in N[v]$ **wykonaj**

jeżeli $pos[u] = -1$ **to**

$\Delta \leftarrow p_u - (d_{v,u} + d_{u,w} - d_{v,w});$

jeżeli $\Delta > \Delta_{best}$ **to** $\Delta_{best} \leftarrow \Delta;$

$m_{best} \leftarrow \text{Add}(u, v, w);$

w przeciwnym razie

$u_{next} \leftarrow x[(pos[u]+1) \bmod n];$

jeżeli $u \neq v \wedge u \neq w \wedge u_{next} \neq v$ **to**

$\Delta \leftarrow (d_{v,w} + d_{u,u_{next}}) - (d_{v,u} + d_{w,u_{next}});$

jeżeli $\Delta > \Delta_{best}$ **to** $\Delta_{best} \leftarrow \Delta;$

$m_{best} \leftarrow \text{2-opt}(v, w, u, u_{next});$

koniec

koniec

koniec

koniec

dla każdego $i = 0, \dots, n-1$ **wykonaj**

$v_{prev} \leftarrow x[(i-1+n) \bmod n]; \quad v \leftarrow x[i]; \quad w \leftarrow x[(i+1) \bmod n];$

$\Delta \leftarrow (d_{v_{prev},v} + d_{v,w} - d_{v_{prev},w}) - p_v;$

jeżeli $\Delta > \Delta_{best}$ **to** $\Delta_{best} \leftarrow \Delta;$

$m_{best} \leftarrow \text{Remove}(v);$

koniec

jeżeli $\Delta_{best} > 0$ **to**

 Wykonaj ruch m_{best} na trasie $x;$

$improved \leftarrow \text{prawda};$

koniec

koniec

zwróć x

Algorithm 2: Rekombinacja Op1 / Op2 (wspólne krawędzie)

Wejście: Rodzice p_1, p_2 ; macierz odległości D ; lista zysków p ; flaga *keepSingles* (Op1: **prawda**; Op2: **fałsz**)

Wyjście: Dziecko c

$cv \leftarrow \text{vertices}(p_1) \cap \text{vertices}(p_2)$ $ce \leftarrow \text{edges}(p_1) \cap \text{edges}(p_2)$

$subs \leftarrow []$; $cur \leftarrow []$;

Znajdź punkt startowy: pierwsza pozycja w p_1 , gdzie wierzchołek lub krawędź wchodząca $\notin cv/ce$;

dla każdego wierzchołka v w p_1 od punktu startowego wykonaj

jeżeli $v \in cv$ **i** krawędź wchodząca do $v \in ce$ **to**

 Dołącz v do cur ;

w przeciwnym razie

jeżeli $|cur| > 0$ **to**

jeżeli *keepSingles* **lub** $|cur| > 1$ **to** dołącz cur do $subs$;

$cur \leftarrow []$;

koniec

jeżeli $v \in cv$ **to** $cur \leftarrow [v]$;

koniec

koniec

jeżeli $|cur| > 0$ **i** (*keepSingles* **lub** $|cur| > 1$) **to** dołącz cur do $subs$;

Przetasuj $subs$ losowo;

$c \leftarrow []$;

dla każdego podtrasa $s \in subs$ wykonaj

 Z prawdopodobieństwem $\frac{1}{2}$ odwróć s ;

$c \leftarrow c \parallel s$;

koniec

$c \leftarrow \text{RepairLNS}(c, D, p)$;

$c \leftarrow \text{phase2_remove}(c, D, p)$;

zwróć c

Algorithm 3: HAE-CLS

Wejście: Macierz odległości D , lista zysków p , limit czasu T , rozmiar populacji elitarnej P , lista sąsiadów N (k najbliższych dla każdego wierzchołka)

Wyjście: Najlepsze znalezione rozwiązanie x_{best}

$pop \leftarrow \emptyset$; $prby \leftarrow 0$;

dopóki $|pop| < P \wedge prby < 20P$ **wykonaj**

$x \leftarrow$ losowe rozwiązanie startowe;

$x \leftarrow \text{CandLS}(x, D, p, N)$;

jeżeli $\nexists y \in pop : f(y) = f(x)$ **to** $pop \leftarrow pop \cup \{x\}$;

$prby \leftarrow prby + 1$;

koniec

dopóki $|pop| < P$ **wykonaj**

$x \leftarrow \text{CandLS}(\text{losowe rozwiązanie}, D, p, N)$; $pop \leftarrow pop \cup \{x\}$;

koniec

$x_{best} \leftarrow \arg \max_{x \in pop} f(x)$;

dopóki $\text{czas}() < T$ **wykonaj**

 Wylosuj różnych rodziców p_a, p_b z pop ;

$c \leftarrow \text{Op1}(p_a, p_b, D, p)$ $c \leftarrow \text{CandLS}(c, D, p, N)$ $x_{worst} \leftarrow \arg \min_{x \in pop} f(x)$;

jeżeli $f(c) > f(x_{worst}) \wedge \nexists y \in pop : f(y) = f(c)$ **to**

$pop \leftarrow (pop \setminus \{x_{worst}\}) \cup \{c\}$;

jeżeli $f(c) > f(x_{best})$ **to** $x_{best} \leftarrow c$;

koniec

koniec

zwróć x_{best}

Wartości parametrów użyte w eksperymentach finalnych: $P = 15$, $k = 15$, $T_A = 1420$ ms, $T_B = 1578$ ms. Wybór P oraz k uzasadniony w Fazie II tuningu.

4 Eksperymenty i testowane warianty

Wybór finalnej metody poprzedziły dwie fazy eksperymentów: (i) przesiew pięciu różnych technik rozszerzających HAE; (ii) tuning siatkowy parametrów op , k , P i ALNS.

4.1 Faza I: przesiew technik rozszerzających HAE

W pierwszym kroku zaimplementowano pięć niezależnych modyfikacji HAE i uruchomiono je po 5 razy (przesiew zgrubny) w standardowym budżecie czasowym ($T_A = 1420$ ms, $T_B = 1578$ ms).

- **HAE2_base** – referencyjny HAE2 ($op2 + SLS +$ populacja 20)
- **M1_candLS** – HAE2, lecz SLS zastąpione przez CandLS ($k = 10$).
- **M2_SA** – HAE2 z kryterium akceptacji typu *Simulated Annealing*: dziecko gorsze od najgorszego osobnika populacji jest akceptowane z prawdopodobieństwem $\exp(\Delta/T)$ (chłodzenie geometryczne $T_0 = 200$, $\alpha = 0,999$).
- **M3_ALNS** – adaptacyjny wybór operatora rekombinacji ($op1/op2/op3$) metodą koła ruletki, z wagami uaktualnianymi co 20 iteracji na podstawie skuteczności.
- **M4_meme** – intensyfikacja memetyczna: co 50 iteracji krótkie ILS (5 perturbacji) na 3 najlepszych osobnikach populacji.
- **M5_M1+M3** – M1 i M3 połączone.

Wariant	TSPA Avg	TSPA Max	TSPB Avg	TSPB Max
HAE2_base	7742	8034	19879	20000
M1_candLS	8456	8581	20014	20074
M2_SA	7897	7980	19766	19966
M3_ALNS	8115	8325	19817	19954
M4_meme	8056	8322	19813	19921
M5_M1+M3	8369	8581	20042	20128

Tabela 1: Faza I: 5 uruchomień przesiewowych każdego wariantu. Pogrubione: kandydaci do dalszego tuningu (M1 i M5 weszły do Fazy II).

Wnioski z Fazy I:

- **CandLS kluczowy** – M1 podnosi średnią o ok. 700 jednostek na TSPA i 135 na TSPB względem HAE2_base.
- **SA** – akceptacja gorszych dzieci nie pomaga; elitarna populacja i tak utrzymuje dywersyfikację (unikalność po wartości celu).
- **ALNS i memetic** – niewielka poprawa, ale niższa niż samo M1.
- **M5** (M1+ALNS) – daje wyniki porównywalne z M1

4.2 Faza II: Grid search

W drugiej fazie przeszukano siatkę parametrów wokół M1 i M5 – oba bazujące na CandLS):

$$\text{op} \in \{1, 2\}, \quad k \in \{5, 10, 15, 20\}, \quad P \in \{15, 20, 25\}, \quad \text{ALNS} \in \{\text{wł.}, \text{wył.}\}.$$

Każdą kombinację oceniono znormalizowaną poprawą średnich względem HAE2 z Zadania 6:

$$\text{score}(\text{cfg}) = \frac{a_{\text{avg}}(\text{cfg}) - 7916}{7916} + \frac{b_{\text{avg}}(\text{cfg}) - 19868}{19868}.$$

Konfiguracja	TSPA Avg	TSPA Max	TSPB Avg	TSPB Max
op=1, k=15, P=15, ALNS=wył. (HAE-CLS)	8473	8624	20023	20155
op=1, k=20, P=20, ALNS=wył.	8436	8617	20014	20158
op=2, k=20, P=20, ALNS=wył.	8404	8615	20039	20164
op=1, k=20, P=15, ALNS=wył.	8402	8624	19997	20148
op=2, k=10, P=15, ALNS=wył.	8313	8591	20003	20139

Tabela 2: Faza II – top-5 konfiguracji z 48 testowanych (20 uruchomień każda). Krajobraz hiperparametrów płaski w okolicy optimum: top-5 mieści się w przedziale ± 60 na średniej TSPA i ± 40 na TSPB. Wartości zmierzone w trybie zrównoleglonym (4 workery), z niewielkim wpływem CPU contention.

4.3 Ablacja składowych algorytmu


Aby zweryfikować, czy konfiguracja zwycięska jest stabilnie najlepsza, przeprowadzono ablację jednoparametrową: każdy wariant różni się od HAE-CLS *dokładnie jedną* modyfikacją (20 uruchomień).

Wariant	TSPA Avg	TSPA Max	TSPB Avg	TSPB Max	TSPA iter.
HAE-CLS (ref)	8430	8615	19989	20146	1774
HAE-CLS + NN init	8339	8591	19984	20139	1644
HAE-CLS, LM zamiast CandLS	7988	8545	19941	20118	196
HAE-CLS z op3 zamiast op1	7354	7892	18919	19226	2006
HAE-CLS + akceptacja SA	8437	8624	19983	20097	1903
HAE-CLS + ALNS	8411	8581	19964	20139	2036


Wnioski z ablacji:

- **LM zamiast CandLS:** spadek do 196 iter. na TSPA ($9\times$ mniej) i -442 obj średniej – LM ma zbyt duży overhead utrzymywania kolejki ruchów, by zwrócić się w budżecie 1,4–1,6 s.
- **op3:** katastrofalne -1076 obj na TSPA i -1070 obj na TSPB – potwierdzenie ustalenia z Fazy I (op3 wyklucza zbyt wiele wierzchołków z rodziców).
- **NN init, SA, ALNS:** różnice w granicach ± 30 obj średniej – szum statystyczny, mechanizmy nie poprawiają zwycięskiej konfiguracji ani jej istotnie nie pogarszają. SA daje marginalnie lepsze *max* na TSPA (8624 vs 8615), ale różnica jest niezauważalna na poziomie pojedynczych runs.

4.4 Konwergencja w czasie



(a) TSPA (limit 1420 ms)



(b) TSPB (limit 1578 ms)


5 Wyniki finalne

5.1 Tabela porównawcza


Algorytm	Wynik Avg (Min – Max)	Avg Iteracji
<i>Instancja TSPA – limit czasu 1420 ms</i>		
MSLS	7692 (7437 – 7997)	200
ILS	8135 (7531 – 8420)	3807
LNS	8134 (7593 – 8571)	314
HAE2	7916 (7649 – 8473)	217
HAE-CLS	8497 (8180 – 8624)	1828
Poprawa HAE-CLS vs best-of-prior: avg +362 (+4,4%) vs ILS, max +44 (+0,5%) vs LNS		
<i>Instancja TSPB – limit czasu 1578 ms</i>		
MSLS	19370 (19003 – 19791)	200
ILS	19786 (19430 – 20045)	3999
LNS	19769 (19591 – 19967)	463
HAE2	19868 (19717 – 20055)	389
HAE-CLS	20025 (19845 – 20155)	2950
Poprawa HAE-CLS vs best-of-prior: avg +110 (+0,6%) vs HAE2, max +100 (+0,5%) vs HAE2		

6 Wizualizacje najlepszych rozwiązań


Porównanie wizualne najlepszych tras dla sześciu kluczowych metod (SLS i CLS z Zad. 3, ILS i LNS z Zad. 4, HAE2 z Zad. 6, HAE-CLS z Zad. 7) na obu instancjach.




(a) SLS (Zad. 3)




(b) CLS (Zad. 3)




(c) ILS (Zad. 4)



(d) LNS (Zad. 4)




(e) HAE2 (Zad. 6)




(f) HAE-CLS (Zad. 7) – najlepszy 8615


Rysunek 2: TSPA – porównanie sześciu metod.




(a) SLS (Zad. 3)




(b) CLS (Zad. 3)




(c) ILS (Zad. 4)



(d) LNS (Zad. 4)



(e) HAE2 (Zad. 6)



(f) HAE-CLS (Zad. 7) – najlepszy 20155

Rysunek 3: TSPB – porównanie sześciu metod.

7 Wnioski

1. **CandLS jako jedyne istotne źródło poprawy.** Spośród pięciu zaproponowanych modyfikacji (CandLS, SA, ALNS, memetic, M5 = CandLS+ALNS) tylko CandLS dał wyraźny wzrost jakości. Klucz tkwi w przyspieszeniu lokalnego przeszukiwania o rząd wielkości – pozwala to wykonać 7–10× więcej iteracji ewolucyjnych w tym samym budżecie czasu (HAE2 ≈ 220 iter., HAE-CLS ≈ 1800 –3000 iter.). *Liczba dobrze skonwergowanych iteracji* okazała się ważniejsza niż jakość pojedynczej iteracji. Dekompozycja poprawy: sam CandLS (wariant M1) podnosi TSPA avg z 7742 do 8456 (+**714 obj**), co stanowi praktycznie całość zysku względem HAE2; dostrojenie hiperparametrów (op, k, P) dodaje już tylko drobną korektę w granicach szumu pomiarowego.
2. **Nieoczywiste interakcje hiperparametrów.** W Zadaniu 6 najlepszym operatorem rekombinacji był Op2; po zmianie LS na CandLS okazało się, że Op1 daje porównywalne lub lepsze wyniki. Mniejsza populacja ($P=15$) okazała się lepsza niż domyślne $P=20$. Sugeruje to, że *strojenie hiperparametrów po każdej istotnej zmianie algorytmu jest konieczne* – ustawienia dziedziczone z wcześniejszej wersji nie są optymalne.
3. **Krajobraz hiperparametrów jest płaski w okolicy optimum.** Top-5 konfiguracji z tuningu siatkowego mieści się w przedziale ± 60 na średniej; najlepszy wynik (max) 8624 powtarza się dla 3 różnych konfiguracji. Sugeruje to, że HAE-CLS osiąga sufit jakości algorytmu w ramach tej rodziny metod.